

Zeitreihenanalyse

Kapitel 3) Weitere Themen zur Zeitreihenregression

Kapitel 3.1) Vektorautoregressionen

Markus Mößler

markus.moessler@lb.hfwu.de

Hochschule für Wirtschaft und Umwelt (HfWU)
Zukunftsökonomie (B.Sc.)

Sommer 2026



Hochschule
für Wirtschaft und Umwelt
Nürtingen-Geislingen

Einordnung des Kapitel 3) (Kapitel 17 in S&W 2020):

- Kapitel 17 von S&W 2020 behandelt weiterführende Themen der Zeitreihenregression.
- Der Fokus hier liegt auf dem Thema Zeitreihenprognose

Themen des Kapitel 3):

- 1.1) Vektorautoregressionen (VAR)
- 1.2) Mehrperiodige Prognosen
- 1.6) Viele Prädiktoren und dynamische Faktormodelle

Die weiteren Themen aus Kapitel 17 in S&W 2020 werden nicht weiterführend betrachtet.

Einführung

- In vielen Anwendungen sollen mehrere ökonomische Zeitreihen gleichzeitig prognostiziert werden.
- Beispiele: BIP-Wachstum, Inflation, Arbeitslosenquote oder Zinssätze.
- Zwischen diesen Variablen bestehen häufig dynamische Wechselwirkungen.

Motivation

- Ziel: Mehrere Zeitreihenvariablen gemeinsam vorhersagen.
- Alternative zu separaten Prognosemodellen für jede Variable.
- Lösung: Vektorautoregression (VAR).
- Erweitert univariate Autoregression auf ein „Vektor“-Modell.

Definition: VAR-Modell

- Ein VAR(p)-Modell mit k Variablen besteht aus k Gleichungen.
- Jede Gleichung enthält p verzögerte Werte aller k Variablen.
- Beispiel für 2 Variablen Y_t und X_t :

Beispiel: 2 Variablen Y_t und X_t

$$Y_t = \beta_{10} + \sum_{j=1}^p \beta_{1j} Y_{t-j} + \sum_{j=1}^p \gamma_{1j} X_{t-j} + u_{1t}$$
$$X_t = \beta_{20} + \sum_{j=1}^p \beta_{2j} Y_{t-j} + \sum_{j=1}^p \gamma_{2j} X_{t-j} + u_{2t}$$

Schlüsselkonzept: Vektorautoregressionen

Eine Vektorautoregression (VAR) ist ein System aus k Zeitreihenregressionen, bei denen die Regressoren verzögerte Werte aller k Variablen sind. Eine Vektorautoregression erweitert die univariate Autoregression auf einen Vektor von Zeitreihenvariablen.. Wenn jede Gleichung dieselbe Anzahl an Lags p verwendet, nennt man das System eine VAR(p).

Beispiel für zwei Zeitreihenvariablen Y_t und X_t :

$$\begin{aligned} Y_t &= \beta_{10} + \beta_{11}Y_{t-1} + \dots + \beta_{1p}Y_{t-p} + \gamma_{11}X_{t-1} + \dots + \gamma_{1p}X_{t-p} + u_{1t} \\ X_t &= \beta_{20} + \beta_{21}Y_{t-1} + \dots + \beta_{2p}Y_{t-p} + \gamma_{21}X_{t-1} + \dots + \gamma_{2p}X_{t-p} + u_{2t} \end{aligned} \quad (1)$$

Schätzung:

- Die Koeffizienten β und γ sind unbekannt; u_{1t} und u_{2t} sind Fehlerterme.
- Jede Gleichung wird mit OLS geschätzt.

Schätzung und Inferenz

- Jede Gleichung wird mit OLS separat geschätzt.
- Schätzer sind konsistent und asymptotisch normalverteilt.
- Gemeinsame Hypothesentests über mehrere Gleichungen sind möglich.
- z.B.: Test auf optimale Verzögerungslänge p mittels F-Test.

Wahl der Anzahl von Variablen

- Die Anzahl der Koeffizienten steigt schnell mit k und p .
- Beispiel: 5 Variablen, 4 Lags $\Rightarrow$ 105 Koeffizienten!
- Empfehlung: Nur wenige, aber relevante Variablen wählen.
- Unrelevante Variablen erhöhen Schätzfehler und senken Prognosegüte.

Wahl der Anzahl der Lags

- Die optimale Laglänge kann bestimmt werden über:
 - F-Tests oder
 - Informationskriterien (AIC, BIC)
- BIC-Formel:

$$\text{BIC}(p) = \ln \det (\hat{\Sigma}_u) + \frac{k(kp + 1) \ln(T)}{T} \quad (2)$$

VAR für kausale Analyse

- VAR-Modelle können auch für Kausalitätsanalysen verwendet werden.
- Voraussetzung: Strukturannahmen aus Theorie notwendig.
- Stichwort: Struktur-VAR (structural VAR) (see Sims 1980).

Gleichung 1: BIP-Wachstumsrate

$$\widehat{\text{GDPGR}}_t = \underset{(0.50)}{0.54} + \underset{(0.11)}{0.29} \text{GDPGR}_{t-1} + \underset{(0.08)}{0.20} \text{GDPGR}_{t-2} \\ - \underset{(0.35)}{0.86} \text{TSpread}_{t-1} + \underset{(0.39)}{1.18} \text{TSpread}_{t-2} \quad (3)$$

Gleichung 2: Laufzeit-Spread

$$\widehat{\text{TSpread}}_t = \underset{(0.12)}{0.44} + \underset{(0.02)}{0.01} \text{GDPGR}_{t-1} - \underset{(0.03)}{0.05} \text{GDPGR}_{t-2} \\ + \underset{(0.10)}{1.06} \text{TSpread}_{t-1} - \underset{(0.11)}{0.22} \text{TSpread}_{t-2} \quad (4)$$

Test auf Vorhersagekraft

- Vorhersagekraft von TSpread-Lags für GDPGR

$$H_0: \gamma_{11} = \gamma_{12} = 0$$

$$F = 5,60, p < 0,001$$

⇒ Signifikante Vorhersagekraft basierend auf Gleichung 3

- Vorhersagekraft von GDPGR-Lags für TSpread

$$H_0: \beta_{21} = \beta_{22} = 0$$

$$F = 3,22, p = 0,04$$

⇒ Signifikante Vorhersagekraft auf 5%-Niveau basierend auf Gleichung 4

Einperioden-Prognosen für 2017:Q4

- $\widehat{\text{GDPGR}}_{2017:Q4} = 2,8\%$ vs. 2,5% (tatsächlich)
- $\widehat{\text{TSpread}}_{2017:Q4} = 1,3$ Prozentpunkte vs. 1,2 Prozentpunkte (tatsächlich)

Fazit zur Verwendung von Vektorautoregressionen

- VAR-Modelle sind nützlich für die gemeinsame Modellierung mehrerer Zeitreihen.
- OLS-Schätzung erlaubt einfache Implementierung.
- Sorgfältige Wahl von Variablen und Lags entscheidend.
- Neben Prognosen auch für strukturelle Analysen einsetzbar.

Grundlegende Literatur zu kausalen Analyse mit VAR-Modellen

Christopher A. Sims (1980). „Macroeconomics and Reality“. In: [Econometrica](#) 48.1, S. 1–48

Generelle Anwendungen von VAR-Modellen

- James H. Stock und Mark W. Watson (Dez. 2001). „Vector Autoregressions“. In: [Journal of Economic Perspectives](#) 15.4, S. 101–115