

Zeitreihenanalyse

Kapitel 3) Weitere Themen zur Zeitreihenregression

Kapitel 3.3) Dynamischer Faktormodelle und Hauptkomponenten

Markus Mößler

markus.moessler@lb.hfwu.de

Hochschule für Wirtschaft und Umwelt (HfWU)
Zukunftsökonomie (B.Sc.)

Sommer 2026



Hochschule
für Wirtschaft und Umwelt
Nürtingen-Geislingen

Einführung & Motivation

Ausgangsproblem

- Moderne Datenbanken enthalten oft hunderte oder tausende Zeitreihen.
- Beispiele: Produktion, Beschäftigung, Inflation, Zinsen, Finanzmarktvariablen
- Viele dieser Variablen enthalten Informationen für Prognosen.

Herausforderungen

- Viele Prädiktoren
 - ⇒ Overfitting.
 - ⇒ Multikollinearität.
- ⇒ OLS liefert häufig schlechte Prognosen außerhalb der Stichprobe.

Leitfrage

- ⇒ Wie können wir die Information vieler Variablen effizient für Prognosen nutzen?

Einführung in Hauptkomponenten

- Ziel: Reduktion der Dimension bei vielen Regressoren.
- Hauptkomponenten sind lineare Kombinationen der ursprünglichen Variablen.
- Die erste Hauptkomponente erklärt den größten Anteil der Gesamtvarianz.
- Die Hauptkomponenten sind unkorreliert zueinander.

Eigenschaften der Hauptkomponenten: Für k standardisierte Variablen $X_1, \dots, X_k$ gilt,

1. Die quadrierten Gewichte jeder Komponente summieren sich zu 1.
2. Die erste Komponente maximiert die Varianz.
3. Die j -te Komponente maximiert die Varianz unter der Bedingung, dass sie unkorreliert mit den vorherigen ist.
4. Die Anzahl der Hauptkomponenten ist $\min(n, k)$.

Mathematische Definition

- Die Summe der Varianzen der Hauptkomponenten entspricht der Summe der Varianzen der X -Variablen:

$$\sum_{j=1}^{\min(n,k)} \text{Var}(PC_j) = \sum_{j=1}^k \text{Var}(X_j)$$

- Der Anteil der durch PC_j erklärten Gesamtvarianz:

$$R_j^2 = \frac{\text{Var}(PC_j)}{\sum_{j=1}^k \text{Var}(X_j)}$$

Scree-Plot

- Zeigt den Anteil der Gesamtvarianz, der durch jede Hauptkomponente erklärt wird.
- Typisch: starke Erklärungskraft durch erste Komponenten, danach Abflachung ($\Rightarrow$ „Klippenstruktur“).

Anwendung in der Regressionsanalyse

- Viele erklärende Variablen $\Rightarrow$ Überfitting oder Multikollinearität.
- Statt sehr vielen Variablen: Nutzung von z.B. 10 Hauptkomponenten.
- Auswahl der Anzahl p durch Minimierung des mittleren quadratischen Prognosefehlers (MSFE), z.B. per POOS Analyse.

Fazit

- Hauptkomponentenanalyse ist ein effektives Werkzeug zur Dimensionsreduktion.
- Hauptkomponenten erfassen einen Großteil der Varianz mit wenigen linearen Kombinationen.
- Besonders nützlich bei vielen stark korrelierten Variablen.

Schlüsselkonzept: Die Hauptkomponenten von $\mathbf{X}$

(1/2)

Die Hauptkomponenten der k Variablen $X_1, \dots, X_k$ sind lineare Kombinationen von X , die folgende Eigenschaften erfüllen:

1. Die quadrierten Gewichte der linearen Kombinationen summieren sich zu 1;
2. Die erste Hauptkomponente maximiert die Varianz ihrer linearen Kombination;
3. Die zweite Hauptkomponente maximiert die Varianz ihrer linearen Kombination, unter der Bedingung, dass sie unkorreliert mit der ersten Hauptkomponente ist;
4. Allgemeiner: Die j -te Hauptkomponente maximiert die Varianz ihrer linearen Kombination, unter der Bedingung, dass sie unkorreliert mit den ersten $j - 1$ Hauptkomponenten ist.

Schlüsselkonzept: Die Hauptkomponenten von $\mathbf{X}$

(2/2)

- Wenn keine perfekte Multikollinearität in $\mathbf{X}$ vorliegt, ist die Anzahl der Hauptkomponenten $\min(n, k)$.
- Die Summe der Stichprobenvarianzen der Hauptkomponenten entspricht der Summe der Stichprobenvarianzen der $\mathbf{X}$ -Variablen:

$$\sum_{j=1}^{\min(n, k)} \text{Var}(PC_j) = \sum_{j=1}^k \text{Var}(X_j)$$

- Das Verhältnis $\frac{\text{Var}(PC_j)}{\sum_{j=1}^k \text{Var}(X_j)}$ ist der Anteil der Gesamtvarianz der $\mathbf{X}$ -Variablen, der durch die j -te Hauptkomponente erklärt wird. Dieses Maß ist vergleichbar mit einem R^2 .

Motivation

- Viele makroökonomische Variablen bewegen sich gemeinsam.
- Beispiel: Produktion, Beschäftigung, Inflation, Zinsen.
- Ziel: Gemeinsame Faktoren identifizieren, die diese Bewegungen erklären.
- Problem: Viele Prädiktoren $\Rightarrow$ OLS-Vorhersagen unzuverlässig.

Grundidee des DFM

- Modelliert gemeinsame Bewegungen vieler Zeitreihen durch wenige latente Faktoren.
- Diese Faktoren sind nicht beobachtbar also latent.
- Verwendung von Hauptkomponenten zur Schätzung der Faktoren.

Modellstruktur: Messgleichung,

$$X_{it} = \Lambda_{i0} + \Lambda_{i1}F_{1t} + \dots + \Lambda_{ir}F_{rt} + u_{it}$$

- X_{it} : beobachtete Zeitreihe i
- F_{jt} : latente Faktoren
- Λ_{ij} : Faktorladegewichte
- u_{it} : idiosynkratische Störungen

Dynamik der Faktoren: Faktorgleichung (VAR(1)-Beispiel),

$$\mathbf{F}_t = A\mathbf{F}_{t-1} + \mathbf{h}_t$$

- Die Faktoren selbst folgen einem VAR-Prozess.
- Modelliert zeitliche Abhängigkeiten der Faktoren.

DFM: Schätzung und Prognose

Schätzung des Modells

- Faktoren sind nicht beobachtbar – sie werden durch Hauptkomponenten (Principal Components) geschätzt.
- Sobald geschätzte Faktoren $\hat{F}_t$ vorliegen, können OLS-Schätzungen für Λ und A durchgeführt werden.

Prognose mit dem DFM

- Das Modell verwendet geschätzte Faktoren, um zukünftige Werte der Zeitreihen vorherzusagen.
- Die Prognose basiert auf den VAR-Dynamiken der Faktoren.
- Vorteil: Umfassende Nutzung vieler Zeitreihen ohne Überanpassung.

Einführung

- Verwendung von dynamischen Faktormodellen (DFM) zur Prognose makroökonomischer Variablen.
- Datensatz: 131 quartalsweise US-Zeitreihen (1960:Q1 – 2017:Q4).
- Ziel: Identifikation gemeinsamer Bewegungen in vielen Variablen.

Datenbeschreibung

- Daten umfassen BIP, Beschäftigung, Inflation, Zinssätze, Ölpreise etc.
- Transformation der Daten zur Eliminierung stochastischer Trends.
- Standardisierung vor der Faktoranalyse (z-Transformation).

TABLE 17.2 The Quarterly Macroeconomic Data Set

Category	Number of Series Used for Factor Estimation
National Income and Product Accounts	13
Industrial Production	8
Employment and Unemployment	30
Orders, Inventories, and Sales	6
Housing Starts and Permits	6
Prices	22
Productivity and Labor Earnings	5
Interest Rates	10
Money and Credit	6
International	8
Asset Prices, Wealth, Household Balance Sheets	10
Other	2
Oil Market Variables	5
Total	131

Faktorauswahl

- Hauptkomponentenanalyse
- Scree-Plot: Erster Faktor erklärt 20%, erste vier erklären zusammen 39% der Gesamtvarianz.
- Bai–Ng-Informationskriterium wählt $r = 4$ Faktoren.

Gemeinsame Komponenten

- Schätzung gemeinsamer Komponenten für BIP, Beschäftigung, Ölpreise und Aktienrenditen.
- Selbst aggregierte Größen wie BIP werden durch die Faktoren gut approximiert.
- Hohe Erklärungsleistung trotz einfacher Modellstruktur.

FIGURE 17.4 Scree Plot of First 30 Factors for the Macro Data Set, 1960–2017

The first factor explains 20% of the total variance of the series, and the first four factors collectively explain 39% of the total variance of the series.

Fraction of total variance of X explained





FIGURE 17.5 Four-Quarter Growth Rates, Actual and Common Components, 1960–2017

The series (black) and estimated common components (blue) of GDP, employment, oil prices, and returns on the S&P 500 based on a four-factor DFM, estimated using the 131-series macroeconomic data set, 1960–2017.

Prognosevergleich

- Prognosemodelle: AR(2), ADL(2,2) mit Term-Spread, und DFM mit 4 Faktoren.
- Horizonte: $h = 1, 4, 8$ Quartale.
- Kriterium: RMSFE (Root Mean Square Forecast Error).

Ergebnisse der Prognosen

- DFM-basierte Prognosen schlagen AR und ADL in fast allen Horizonten.
- Besonders gute Leistung während der Finanzkrise 2008–2009.
- Term-Spread liefert keine robusten Prognosen im Out-of-Sample-Vergleich.

TABLE 17.3 Comparison of Direct Forecasts of Cumulative GDP Growth at an Annual Rate: Lagged GDP, Term Spread, and Principal Components, 2002:Q4–2017:Q4

Predictors	$\widehat{RMSFE}_{POOS}$		
	$h = 1$	$h = 4$	$h = 8$
$GDPGR_{t-h}, GDPGR_{t-h-1}$	2.25	1.91	1.74
$GDPGR_{t-h}, GDPGR_{t-h-1}, TSpread_{t-h}, TSpread_{t-h-1}$	2.29	1.94	1.77
$GDPGR_{t-h}, GDPGR_{t-h-1}, \hat{F}_{1t-h}, \hat{F}_{2t-h}, \hat{F}_{3t-h}, \hat{F}_{4t-h}$	2.14	1.40	1.48

Entries are root mean square forecast errors, estimated by pseudo out-of-sample forecasts for the forecast period 2002:Q4–2017:Q4 [Equation (15.22)]. The forecasting models were estimated using data from 1981:Q1 through h periods before 2002:Q4, where h is the forecast horizon. The dependent variable is the h -quarter cumulative growth in GDP at an annual rate, using log points—that is, $(400/h)\ln(GDP_t/GDP_{t-h})$. The regressors are given in the first column, where $\hat{F}_{1t}$ denotes the first factor estimated by the first principal component in the estimation sample and so on. All regressions include an intercept.

Weitere Anwendungen von DFMs

- Konstruktion ökonomischer Indizes (z.B. gleichlaufender Indikator).
- Nowcasting: Prognose aktueller, noch nicht veröffentlichter Daten.
- Flexibler Einsatz trotz teilweiser Datenverfügbarkeit.

Fazit

- DFMs sind nützlich bei vielen Prädiktoren und makroökonomischer Unsicherheit.
- Einfache Faktormodelle erfassen wesentliche gemeinsame Schwankungen.
- Prognosegenauigkeit profitiert von breiter Datenbasis.

Was haben wir gelernt?

- Viele Prädiktoren können Prognosen verschlechtern.
- Hauptkomponentenanalyse (PCA) reduziert die Dimension der Daten.
- Wenige Hauptkomponenten können einen Großteil der Gesamtvarianz erklären.
- Dynamische Faktorenmodelle (DFM) nutzen diese Idee für Zeitreihen.
- Latente Faktoren fassen gemeinsame Bewegungen vieler Variablen zusammen.

Zentrale Erkenntnis

Viele Variablen $\Rightarrow$ wenige Faktoren $\Rightarrow$ robustere Prognosen